

Reporte DAE (Denoising AutoEncoder)

Proyecto 1

Melanie Michel, Santiago Aguirre Vera, Ilse Regina Flores Reyes

Created on March 21 | Last edited on March 21

Objetivo:

El propósito de este experimento fue entrenar un Denoising Autoencoder utilizando un conjunto de imágenes personalizadas de latas de refresco (Coca-Cola, Sprite, etc.), con el objetivo de reconstruir imágenes limpias a partir de versiones con ruido. Este enfoque busca validar la capacidad del modelo para aprender representaciones útiles y realizar restauración de imágenes.

Análisis de Gráficas de Entrenamiento

Se realizaron múltiples runs para comparar el desempeño del modelo bajo la misma arquitectura y configuración base. A continuación se analizan las gráficas más relevantes:

Epoch/loss y epoch/val_loss

- Ambas curvas muestran una disminución clara y progresiva de la pérdida a lo largo de las épocas, lo cual indica que el modelo aprendió a reconstruir las imágenes con éxito.

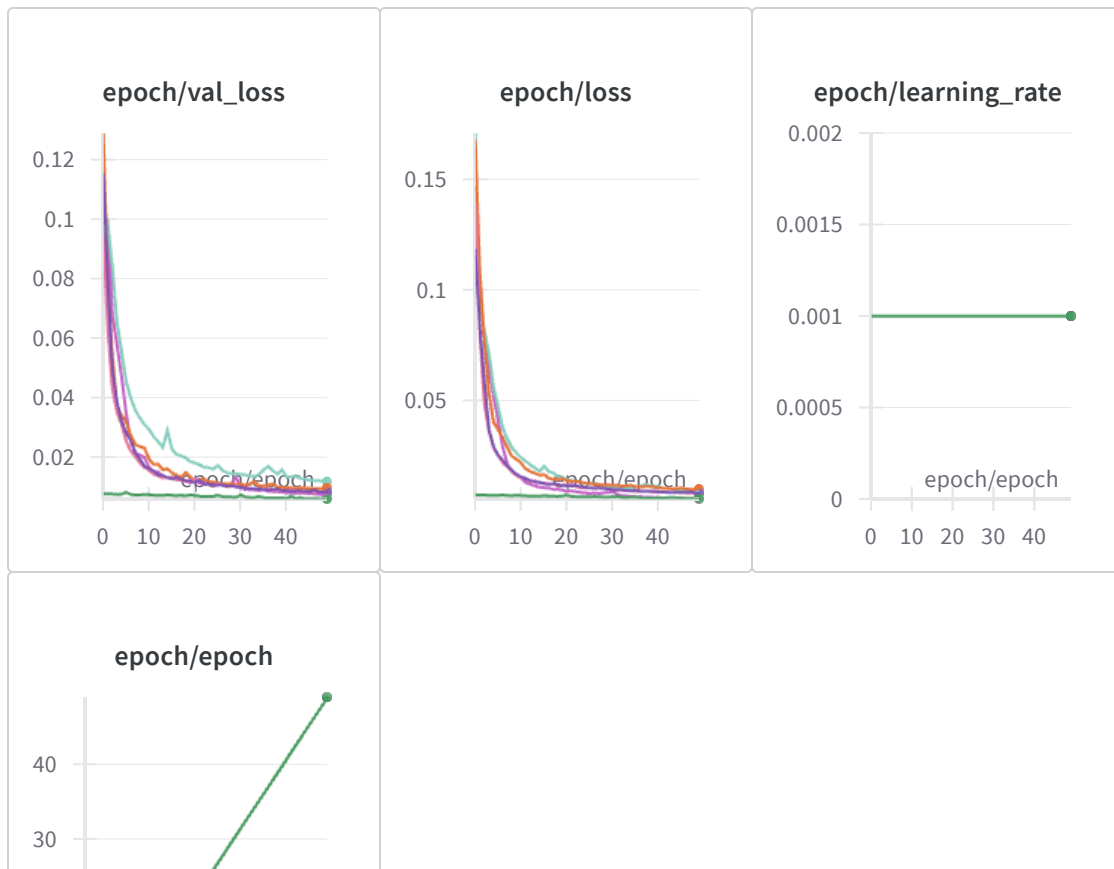
- La pérdida de validación (val_loss) se mantiene cercana a la de entrenamiento, lo que sugiere buen poder de generalización y ausencia de overfitting.
- En la segunda imagen se observa que algunos runs obtuvieron pérdidas notablemente más bajas, lo que indica un mejor desempeño en comparación con otros modelos.


Epoch/learning_rate

- Se mantuvo constante en 0.001 durante todo el entrenamiento, lo cual permitió una convergencia estable sin fluctuaciones agresivas en la pérdida.

Epoch/epoch

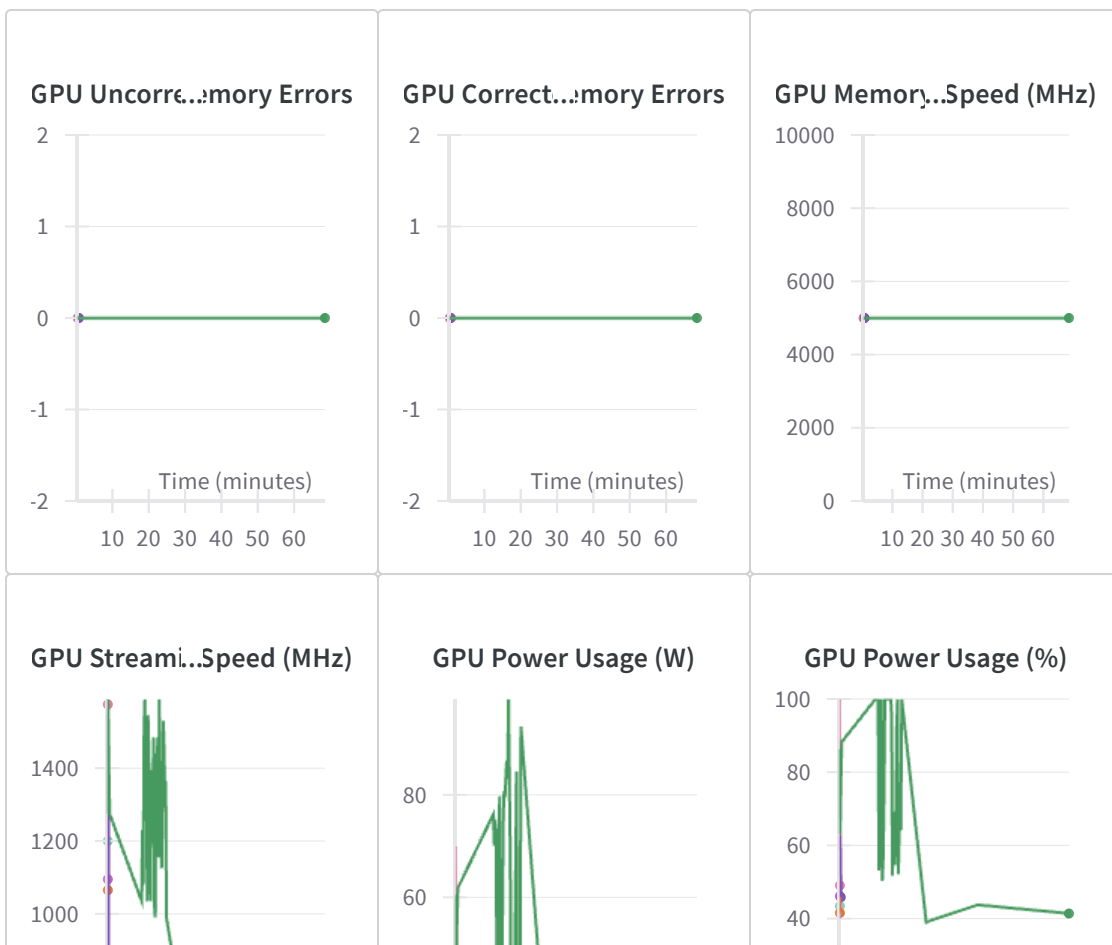
- Simplemente confirma que los modelos fueron entrenados por un total de 45 épocas.






Conclusiones

Las curvas de pérdida reflejan un entrenamiento exitoso y consistente entre todos los runs. Se puede concluir que el autoencoder logró su objetivo de reducir el ruido en las imágenes de refrescos con un error mínimo, especialmente en los mejores experimentos. Las reconstrucciones (visuales) pueden complementar este análisis mostrando qué tan detallada fue la salida final del modelo.





Desempeño GPU

Eficiencia y estabilidad: No hubo errores de memoria, lo que confirma que la GPU manejó la carga sin fallas.

Consumo controlado: La potencia osciló entre 30W y 88W, indicando una ejecución eficiente sin sobrecarga.

Posible optimización: Se podría analizar si la reducción en la frecuencia del SM Clock impacta la velocidad de entrenamiento y si se puede mejorar la utilización de la GPU en fases más avanzadas.

Created with ❤️ on Weights & Biases.

<https://wandb.ai/melaniemichelrod-iteso/denoising-autoencoder/reports/Reporte-DAE-Denoising-AutoEncoder---VmlldzoxMTkxNjAxNQ>