

Reporte VAE (Variational AutoEncoder)

Proyecto 1

Melanie Michel, Santiago Aguirre Vera, Ilse Regina Flores Reyes +

▼ Objetivo:

- ⋮ El objetivo de este proyecto fue implementar un Variational Autoencoder (VAE) utilizando un conjunto de imágenes personalizadas de refrescos (latas de Coca-Cola, Sprite, etc.), con el propósito de que el modelo aprendiera una representación latente probabilística de los datos. A diferencia de un autoencoder clásico, el VAE permite generar nuevas muestras realistas al aprender la distribución del conjunto de imágenes. Esto abre la posibilidad de realizar tareas como generación de imágenes, interpolación en el espacio latente y análisis de variabilidad entre ejemplos.

▼ Análisis Gráficas de Entrenamiento

Epoch/loss y epoch/val_loss

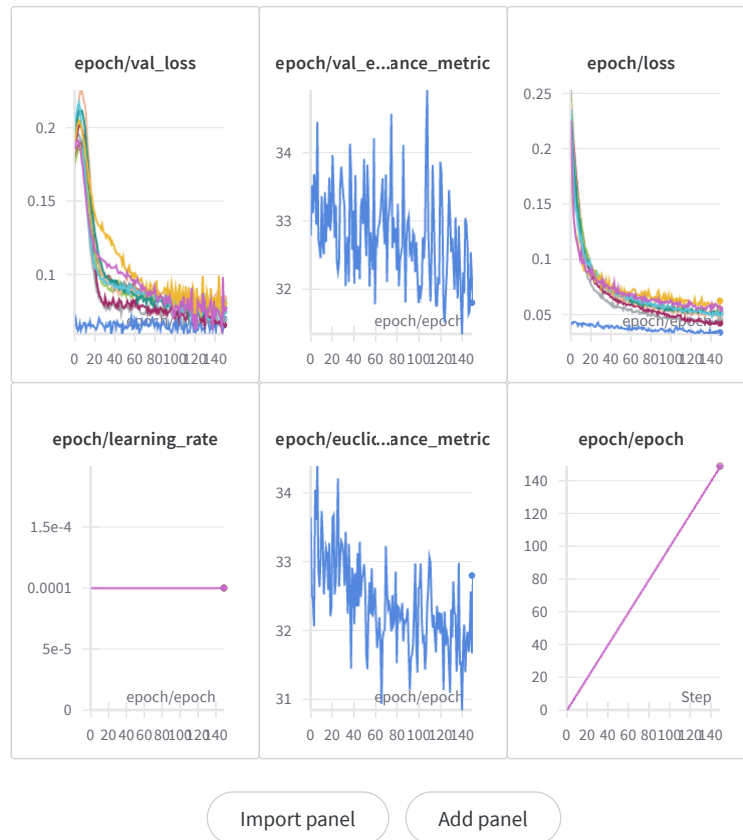
- Las curvas de pérdida muestran una disminución progresiva y consistente durante el entrenamiento (hasta 150 épocas).
- Alrededor de la época 30, la mayoría de los modelos ya alcanzaron una pérdida baja y relativamente estable.
- Las curvas de validación (val_loss) también siguen una tendencia descendente, sin picos abruptos, lo que indica buena generalización y ausencia de overfitting notorio.

Epoch/euclidean_distance_metric y val_euclidean_distance_metric

- Este métrico evalúa la distancia euclidiana entre las imágenes originales y las reconstruidas.
- No hay evidencia de deterioro del desempeño en validación (no hay aumentos sostenidos hacia el final), lo que sugiere estabilidad en las reconstrucciones.


Epoch/learning_rate y epoch/epoch


- El learning rate se mantuvo constante en $1e-4$ durante todo el entrenamiento.
- El entrenamiento se ejecutó durante 150 épocas completas en todos los runs, permitiendo una convergencia completa sin interrupciones.



▼ Conclusiones

Las gráficas indican que el VAE fue entrenado exitosamente, con pérdidas estables y distancias euclidianas razonables.. La estabilidad de las métricas y la ausencia de errores o picos anómalos demuestran que la arquitectura y parámetros elegidos fueron adecuados para el dataset de refrescos.





Import panel

Add panel



▼ Desempeño GPU

Durante el entrenamiento del VAE, la GPU trabajó de forma estable y sin presentar errores. Las gráficas muestran que se aprovecharon bien los recursos: la memoria se mantuvo constante, la frecuencia del procesador gráfico subió y bajó según la carga de trabajo (lo cual es normal), y el consumo de energía estuvo dentro de lo esperado. En resumen, el modelo se entrenó sin problemas técnicos y el uso de la GPU fue eficiente y fluido.